

UNIVERSIDAD TECNOLÓGICA METROPOLITANA
Facultad de Ingeniería — Minería de Datos (INFB8104)

Predicción del cumplimiento de la productividad objetivo en equipos de una fábrica textil

Un enfoque de clasificación supervisada basado en variables operativas y en el
comportamiento temporal reciente de cada equipo

Informe final
Luna León · Matías Machuca

Junio de 2026

Índice

Resumen	3
1. Introducción	3
2. Marco Teórico	3
2.1 Metodologías	3
2.2 Modelos	3
2.3 Herramientas	4
3. Comprensión del Negocio	4
3.1 Definición del Problema	4
3.2 Solución Propuesta	4
3.3 Objetivos	4
3.4 Hipótesis	4
4. Comprensión de los Datos	4
4.1 Descripción del Dataset	4
4.2 Descripción de variables	5
5. Preparación de los Datos	5
5.1 Tratamiento de valores perdidos	5
5.2 Análisis descriptivo de los datos	5
5.3 Transformación de variables	7
5.4 Agrupamiento de variables	7
5.5 Análisis Factorial	8
5.6 Definición de variables Input y Target	9
6. Modelado y Evaluación	10
6.1 Segmentación de los datos	10
6.2 Aplicación de diversos modelos	10
6.3 Validación de los diversos modelos	10
7. Conclusiones	12
7.1 Resumen del trabajo efectuado	12
7.2 Modelo seleccionado y motivos	12
7.3 Aplicación del modelo y extensión del trabajo	13
Referencias	13

Resumen

Este trabajo aborda, mediante técnicas de minería de datos, la predicción de si un equipo de una fábrica textil **alcanzará o no su productividad objetivo** en una jornada, formulada como una **clasificación binaria supervisada** (cumple / no cumple). El aporte central es el uso del **comportamiento temporal reciente de cada equipo** (retardos, medias móviles, tendencia y antigüedad desde el último cambio de estilo). Siguiendo el proceso CRISP-DM (Wirth & Hipp, 2000), se depuró el conjunto de datos de Imran (2020) (1197 registros, 15 variables), se prepararon los datos, se compararon cinco familias de modelos y se validó con una partición temporal. El mejor modelo, un **Random Forest**, **obtuvo un 87.0%** de accuracy, confirmando la hipótesis del 80% y superando la línea base trivial de 73.2%.

1. Introducción

La industria de la confección textil es uno de los sectores manufactureros más intensivos en mano de obra. La unidad operativa fundamental es el **equipo**, y el indicador que gobierna la planificación es la **productividad**: la razón entre lo producido y lo que se esperaba producir en una jornada. A cada equipo se le asigna una productividad objetivo, cuyo cumplimiento determina tiempos de entrega, costos por horas extra y la rentabilidad.

El problema es que la productividad es altamente variable y su incumplimiento suele **constatarse recién al cerrar la jornada**, cuando ya no es posible intervenir. Frente a ello, este proyecto propone un enfoque **predictivo y proactivo**: anticipar, a partir de la información operativa y del **historial reciente de cada equipo**, si éste alcanzará su meta. La pregunta que articula el trabajo es: ¿se puede predecir hoy si un equipo cumplirá su meta a partir de su comportamiento reciente?

El dominio y los datos fueron introducidos por Imran et al. (2019) y difundidos mediante el repositorio UCI (Imran, 2020). A diferencia de otros trabajos que modelan la productividad como valor continuo, aquí se aborda como **clasificación categórica**, con énfasis en la construcción de variables temporales y en la selección de variables de entrada.

2. Marco Teórico

2.1 Metodologías

El trabajo se estructura según **CRISP-DM** (Cross-Industry Standard Process for Data Mining; Wirth & Hipp, 2000), que organiza un proyecto en comprensión del negocio, comprensión de los datos, preparación, modelado y evaluación. La tarea se resuelve con **aprendizaje supervisado**: un modelo aprende, a partir de ejemplos etiquetados, la relación entre variables de entrada y una salida conocida; cuando esa salida es una categoría, se habla de **clasificación**. El objetivo continuo se convierte en binario mediante **discretización**. Para estimar el desempeño de forma honesta se emplean la **validación cruzada** y, dado el componente temporal, una **partición temporal** y la **validación walk-forward**, que evitan la **fuga de información**.

2.2 Modelos

Se comparan familias de clasificación vistas en el ramo. El **árbol de decisión** divide los datos con preguntas sobre las variables. El **Random Forest** combina muchos árboles sobre muestras y variables aleatorias (bagging), reduciendo la varianza. El **AdaBoost** construye árboles secuenciales dando más peso a los casos mal clasificados (boosting). El **Naive Bayes gaussiano** es un

clasificador probabilístico basado en el teorema de Bayes. La **máquina de soporte vectorial (SVM)** busca el hiperplano que mejor separa las clases y requiere estandarizar las variables. Como extensión se consideran algoritmos de **gradient boosting** (XGBoost, LightGBM).

2.3 Herramientas

La implementación se realizó en **Python** sobre **Google Colab**. Se utilizaron: **pandas** y **NumPy** para la manipulación de datos; **scikit-learn** (Pedregosa et al., 2011) para el modelado, la validación y las métricas; **matplotlib** y **seaborn** para la visualización; **XGBoost**, **LightGBM** e **imbalanced-learn** (SMOTE) para la extensión de modelos y el manejo del desbalance; y **ucimlrepo** para la carga del conjunto de datos. La reproducibilidad se garantizó fijando la semilla aleatoria en 42.

3. Comprensión del Negocio

3.1 Definición del Problema

La detección del bajo desempeño productivo es actualmente **reactiva**: se confirma al finalizar la jornada, sin margen de intervención, lo que genera incumplimientos de entrega, sobre costos por horas extra y una supervisión sin criterios anticipatorios. Se requiere un mecanismo que —usando el comportamiento reciente de cada equipo y sus condiciones operativas— permita anticipar el riesgo de incumplimiento y priorizar la supervisión sobre los equipos más vulnerables.

3.2 Solución Propuesta

Se propone un **modelo de clasificación binaria** que, para una jornada dada, prediga si un equipo **cumplirá o no** su productividad objetivo. La solución se apoya en dos pilares: (1) **variables temporales por equipo** que capturan la inercia del desempeño reciente; y (2) una **selección de variables** que gestiona redundancias y evalúa deliberadamente excluir la productividad objetivo (un predictor «atajo»), para demostrar que la predicción se sostiene en información operativa y temporal genuina. El resultado es una herramienta de alerta temprana sobre los equipos en riesgo.

3.3 Objetivos

Objetivo general. Construir y evaluar un modelo de clasificación binaria que determine si un equipo alcanzará su productividad objetivo en una jornada, logrando al menos un 80% de accuracy, a partir de variables operativas y del comportamiento temporal reciente.

Objetivos específicos.

1. Explorar, limpiar y preparar los datos (nulos, corrección de categorías y discretización del target).
2. Construir las variables temporales por equipo (retardo, media móvil, tendencia y antigüedad de estilo).
3. Aplicar selección de variables, evaluando el efecto de excluir la productividad objetivo.
4. Entrenar y comparar modelos de clasificación, evaluándolos con validación adecuada.

3.4 Hipótesis

Es posible construir un modelo de clasificación que determine con al menos un 80% de certeza (accuracy) si un equipo de la fábrica alcanzará su productividad objetivo en una jornada dada, a partir de sus variables operativas y de su comportamiento temporal reciente.

4. Comprensión de los Datos

4.1 Descripción del Dataset

Se utiliza el conjunto **Productivity Prediction of Garment Employees** (Imran, 2020; UCI Machine Learning Repository, id 597), con **1197 registros** y **15 columnas** (11 numéricas y 4 categóricas), correspondientes a un periodo de tres meses (enero a marzo de 2015). Cada registro describe el desempeño de un equipo en una jornada y un departamento.

4.2 Descripción de variables

Tabla 1

Descripción de las variables del conjunto de datos.

Variable	Tipo	Descripción
date	Fecha	Fecha de la jornada
day	Categórica	Día de la semana
quarter	Categórica	Nominalmente «trimestre»; en realidad la semana del mes
department	Categórica	Departamento (sewing / finishing)
team	Categórica	Identificador del equipo (1 a 12)
targeted_productivity	Numérica	Productividad objetivo asignada (0–1)
smv	Numérica	Standard Minute Value: tiempo estándar de la tarea
wip	Numérica	Work in progress: trabajo en proceso
over_time	Numérica	Horas extra (en minutos)
incentive	Numérica	Incentivo económico
idle_time	Numérica	Tiempo ocioso
idle_men	Numérica	Trabajadores inactivos
no_of_style_change	Numérica	Número de cambios de estilo
no_of_workers	Numérica	Número de trabajadores del equipo
actual_productivity	Numérica	Productividad real (0–1)

Nota. Elaboración propia con base en los datos de Imran (2020).

Input candidatos. Como variables de entrada se consideran las **operativas** (smv, wip, over_time, incentive, idle_time, idle_men, no_of_style_change, no_of_workers), las **categóricas** (day, week, department, team) y las **temporales derivadas** que se construyen en la preparación (retardo, media móvil, tendencia y antigüedad de estilo).

Target candidatos. La variable **actual_productivity** (continua, 0–1) es la base del objetivo: se discretiza en la etiqueta binaria **cumple**. La variable **targeted_productivity** interviene en la definición del target (cumple si la real $\geq$ la objetivo); por su vínculo directo con la etiqueta se la trata como predictor «atajo» y se evalúa su exclusión de los inputs.

5. Preparación de los Datos

5.1 Tratamiento de valores perdidos


La variable **wip** presenta **506 valores nulos**, que no son aleatorios: corresponden al departamento finishing, en el que —por la naturaleza del proceso— no existe trabajo en proceso. Por ello se imputan con el valor **0**, decisión semánticamente correcta que además conserva la totalidad de los registros.

5.2 Análisis descriptivo de los datos

El análisis exploratorio (Figura 1) muestra que la productividad real se concentra en valores altos (0,70–0,80), la productividad objetivo adopta valores discretos y las horas extra están sesgadas a la derecha. Al discretizar el objetivo, el balance de clases (Figura 2) es de **875 «cumple» (73.1%)** frente a **322 «no cumple» (26.9%)**: un desbalance relevante, pues un clasificador trivial que siempre predijera «cumple» acertaría cerca del 73.1%.

Figura 1

Distribución de las variables clave.



Nota. Elaboración propia con base en los datos de Imran (2020), procesados con scikit-learn (Pedregosa et al., 2011).

Figura 2

Balance de clases de la variable objetivo (cumple).




Nota. Elaboración propia con base en los datos de Imran (2020), procesados con scikit-learn (Pedregosa et al., 2011).

Se analizaron además los **valores atípicos** con el criterio del rango intercuartílico (IQR; Figura 3, Tabla 2). Se hallaron extremos operativos legítimos (wip hasta 23.122, over_time hasta 25.920) y «atípicos» que son artefactos de variables discretas (no_of_style_change, idle_time). En consecuencia, se optó por **conservarlos** (sin recorte ni winsorización): representan eventos reales que interesa predecir, el Random Forest es robusto a ellos y la SVM se estandariza.

Figura 3

Diagramas de caja de las variables operativas (detección de valores atípicos).

Diagramas de caja de variables operativas (detección de valores atípicos)



Nota. Elaboración propia con base en los datos de Imran (2020), procesados con scikit-learn (Pedregosa et al., 2011).

Tabla 2

Incidencia de valores atípicos por variable según el criterio IQR.

Variable	Atípicos (IQR)	% del total
no_of_style_change	147	12.3%
targeted_productivity	79	6.6%
actual_productivity	54	4.5%
idle_time	18	1.5%
idle_men	18	1.5%
incentive	11	0.9%
wip	9	0.8%
over_time	1	0.1%
smv	0	0.0%
no_of_workers	0	0.0%

Nota. Elaboración propia con base en los datos de Imran (2020).

5.3 Transformación de variables


Se corrigió el error tipográfico del departamento («sweing» → «sewing»); se reinterpreto **quarter** como la **semana del mes** (renombrada week); se convirtió **date** a tipo fecha; y se discretizó el objetivo en **cumple = 1** si $\text{actual_productivity} \geq \text{targeted_productivity}$, y 0 en caso contrario. Además, se **construyeron las variables temporales por equipo** (eje del proyecto): tras ordenar por equipo y fecha se derivaron **prod_lag1** (jornada anterior), **prod_media_movil3** (media de 3 jornadas), **tendencia** (sube/baja) y **reg_desde_cambio_estilo**, todas calculadas **solo con información pasada** para no generar fuga. Finalmente, las categóricas se transformaron con **one-hot encoding**.

5.4 Agrupamiento de variables

Se examinaron las relaciones entre variables numéricas mediante un mapa de calor de correlaciones (Figura 4). Se detectaron **grupos de variables redundantes**: no_of_workers, smv y over_time están fuertemente correlacionadas ($\text{no_of_workers-smv} = 0.91$; $\text{over_time-no_of_workers} = 0.73$), por lo que aportan información parcialmente duplicada. Este agrupamiento orienta la selección de

variables. Adicionalmente, cada variable categórica se agrupa en sus categorías mediante one-hot, y de forma exploratoria se aplicó un agrupamiento no supervisado (K-Means) que se comenta junto al análisis factorial.

Figura 4
Mapa de calor de correlaciones entre las variables numéricas.




Nota. Elaboración propia con base en los datos de Imran (2020), procesados con scikit-learn (Pedregosa et al., 2011).

5.5 Análisis Factorial

Para explorar la estructura latente de los datos y reducir la dimensionalidad se aplicó un **Análisis de Componentes Principales (PCA)**, técnica emparentada con el análisis factorial. Las dos primeras componentes explican solo el **18.8%** de la varianza —reflejo de la alta dimensionalidad tras la codificación— y las clases aparecen **solapadas** (Figura 5). Un agrupamiento **K-Means (k=2)** sobre el mismo espacio no reproduce las clases, lo que confirma que el problema **no es trivialmente separable** y justifica el uso de modelos supervisados no lineales.

Figura 5
Proyección PCA en 2D por clase real (izquierda) y por clúster de K-Means (derecha).




Nota. Elaboración propia con base en los datos de Imran (2020), procesados con scikit-learn (Pedregosa et al., 2011).

5.6 Definición de variables Input y Target

El **target** es la variable binaria **cumple**. Como **inputs** se excluyen date, actual_productivity y cumple (para evitar fuga) y, tras la codificación, se definen dos conjuntos: el **Conjunto A** (34 variables, con targeted_productivity) y el **Conjunto B** (33 variables, sin ese predictor «atajo»). La importancia estimada por Random Forest (Figura 6) guía la selección: entre las variables más relevantes conviven operativas (incentive, smv) con **dos variables temporales construidas en el proyecto** (prod_media_movil3 y prod_lag1), evidencia directa del aporte del historial reciente.

Figura 6

Importancia de variables según Random Forest (Conjunto B).



Nota. Elaboración propia con base en los datos de Imran (2020), procesados con scikit-learn (Pedregosa et al., 2011).

6. Modelado y Evaluación

6.1 Segmentación de los datos

Como el conjunto incorpora variables de historial, **no se usó una partición aleatoria** (provocaría fuga de información). Se empleó una **partición temporal**: entrenamiento con las jornadas más antiguas (anteriores al 2015-02-26, 931 registros) y evaluación con las más recientes (254 registros), reproduciendo el escenario real de predecir el futuro a partir del pasado.

6.2 Aplicación de diversos modelos

Sobre el Conjunto B se entrenaron y compararon cinco modelos: **árbol de decisión**, **Random Forest (300 árboles)**, **AdaBoost (200 estimadores)**, **Naive Bayes gaussiano** y **SVM** (kernel RBF, con estandarización previa), evaluados con validación cruzada estratificada de cinco pliegues. Como extensión, se evaluaron **modelos de gradient boosting** (HistGradientBoosting, XGBoost, LightGBM) y el **manejo del desbalance** (ponderación de clases y sobremuestreo SMOTE), bajo un protocolo de validación más estricto (walk-forward).

6.3 Validación de los diversos modelos

La Tabla 3 y la Figura 7 resumen el accuracy sobre el conjunto de prueba. El mejor modelo fue el **Random Forest, con 87.0%**, seguido por la SVM (85.0%) y AdaBoost (81.1%); tres de los cinco superaron la meta del 80%. Todos superan la línea base trivial de 73.2%.

Tabla 3


Comparación de accuracy por modelo (Conjunto B).

Modelo	Accuracy (test)	¿Supera 80%?
Random Forest	87.0%	Sí
SVM (RBF)	85.0%	Sí
AdaBoost	81.1%	Sí
Naive Bayes (Gaussiano)	78.0%	No
Árbol de Decisión	76.0%	No

Nota. Elaboración propia con base en los datos de Imran (2020).

Figura 7

Comparación del accuracy por modelo frente a la meta del 80%.




Nota. Elaboración propia con base en los datos de Imran (2020), procesados con scikit-learn (Pedregosa et al., 2011).

Las matrices de confusión (Figura 8) muestran el tipo de error. El Random Forest clasificó correctamente 173 de 186 casos «cumple» (recall 93.0%) y 48 de 68 «no cumple» (recall 70.6%), con el mejor equilibrio entre clases —relevante porque no detectar a un equipo en riesgo es el error más costoso.

Figura 8

Matrices de confusión por modelo (Conjunto B).



Nota. Elaboración propia con base en los datos de Imran (2020), procesados con scikit-learn (Pedregosa et al., 2011).

Efecto del predictor «atajo». Con Random Forest, el Conjunto A alcanzó 85.8% y el Conjunto B 87.0%: el hecho de que B iguale e incluso supere a A demuestra que el modelo **no depende del atajo**, sustentándose en variables operativas y temporales genuinas.

Validación adicional. Bajo una validación **walk-forward** (más estricta) con variables enriquecidas y métricas robustas (Tabla 4, Figura 9), el Random Forest se sitúa en torno a 0.808 de accuracy —más realista que el corte único—, las features enriquecidas resultan la mejor palanca, el gradient boosting no supera al RF con este tamaño de datos, y el manejo del desbalance (SMOTE) eleva el F1 de «no cumple» a 0.619 a costa del accuracy, lo que confirma la importancia de elegir una métrica acorde al objetivo.

Tabla 4


Comparación de modelos bajo validación walk-forward y métricas robustas.

Modelo	Accuracy	F1 «no cumple»	PR-AUC «no cumple»
RF (base, proyecto actual)	0.794	0.599	0.669
RF (features enriquecidas)	0.808	0.599	0.670
RF + balance de clases	0.796	0.521	0.676
HistGradientBoosting	0.780	0.583	0.625
XGBoost	0.782	0.586	0.612
LightGBM + balance	0.772	0.616	0.576
XGBoost + SMOTE	0.785	0.619	0.643

Nota. Elaboración propia con base en los datos de Imran (2020).

Figura 9

Comparación de modelos en tres métricas bajo validación walk-forward.



Nota. Elaboración propia con base en los datos de Imran (2020), procesados con scikit-learn (Pedregosa et al., 2011).

7. Conclusiones

7.1 Resumen del trabajo efectuado

Se desarrolló un flujo completo de minería de datos conforme a CRISP-DM para predecir el cumplimiento de la productividad objetivo de equipos textiles, formulado como clasificación binaria. Se comprendió y preparó el conjunto de datos (nulos, transformación, construcción de variables temporales, agrupamiento y reducción dimensional), se definieron los conjuntos de entrada y se compararon cinco modelos bajo una partición temporal, con una validación adicional walk-forward.

7.2 Modelo seleccionado y motivos

Se selecciona el **Random Forest** como modelo final. Los motivos: obtuvo el **mayor accuracy (87.0%)**, superando la meta del 80%; presentó el **mejor equilibrio entre clases** en las matrices de confusión; se mostró el **más estable** bajo la validación walk-forward; y es **robusto a los valores atípicos** y a las variables redundantes. Además, confirmó la hipótesis sin depender del predictor «atajo», apoyándose en las variables temporales creadas en el proyecto.

7.3 Aplicación del modelo y extensión del trabajo

En un uso real, el modelo funcionaría como un **sistema de alerta temprana**: al inicio o durante la jornada estimaría el riesgo de incumplimiento de cada equipo, permitiendo a la supervisión priorizar su atención. Como **extensión**, se propone: optimizar una métrica robusta (F1 / PR-AUC) por el desbalance; adoptar validación walk-forward de forma sistemática; enriquecer aún más la ingeniería de variables temporales; y evaluar gradient boosting con búsqueda de hiperparámetros. El detalle de estas líneas se recoge en el documento complementario de trabajo futuro.

Referencias

- Imran, A. A. (2020). *Productivity prediction of garment employees* [Conjunto de datos]. UCI Machine Learning Repository. <https://doi.org/10.24432/C51S6D>
- Imran, A. A., Amin, M. N., Islam Rifat, M. R., & Mehreen, S. (2019). Deep neural network approach for predicting the productivity of garment employees. En *2019 6th International Conference on Control, Decision and Information Technologies (CoDIT)* (pp. 1402–1407). IEEE. <https://doi.org/10.1109/CoDIT.2019.8820486>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining* (pp. 29–39).