

UNIVERSIDAD TECNOLÓGICA METROPOLITANA
Facultad de Ingeniería — Minería de Datos (INFB8104)

Predicción del cumplimiento de la productividad objetivo en equipos de una fábrica textil

Un enfoque de clasificación supervisada basado en variables operativas y en el
comportamiento temporal reciente de cada equipo

Informe técnico-investigativo

Junio de 2026

Índice

Resumen	3
1. Introducción	3
2. Marco conceptual	4
2.1 Aprendizaje supervisado y clasificación	4
2.2 Discretización del objetivo	4
2.3 Ingeniería de variables temporales	4
2.4 Codificación de variables categóricas	4
2.5 Fuga de información y validación	4
2.6 Modelos de clasificación empleados	4
2.7 Métricas de evaluación	5
3. Problemática, objetivos e hipótesis	5
3.1 Planteamiento de la problemática	5
3.2 Objetivo general	5
3.3 Objetivos específicos	5
3.4 Hipótesis	5
4. Metodología	5
4.1 Comprensión del negocio	5
4.2 Comprensión de los datos	6
4.3 Preparación de los datos	8
4.4 Análisis y tratamiento de valores atípicos (outliers)	9
4.5 Partición temporal y control de la fuga de información	10
4.6 Modelado y selección de variables	10
5. Resultados	12
5.1 Análisis de las matrices de confusión	12
5.2 Efecto del predictor «atajo»	13
5.3 Exploración complementaria: PCA y K-Means	13
6. Discusión	14
7. Desarrollo y validación de las recomendaciones	14
8. Conclusiones	16
9. Trabajo futuro	16
Referencias	16

Resumen

La productividad de los equipos en la industria de la confección textil es un factor crítico para la competitividad, pero presenta una alta variabilidad que dificulta su gestión anticipada. Este trabajo aborda, mediante técnicas de minería de datos, la predicción de si un equipo de una fábrica textil **alcanzará o no su productividad objetivo** en una jornada determinada. El problema se formula como una **clasificación binaria supervisada** (cumple / no cumple), construida discretizando la productividad real respecto de la objetivo. El aporte central del estudio es la incorporación del **comportamiento temporal reciente de cada equipo** —retardos, medias móviles, tendencia y antigüedad desde el último cambio de estilo— en lugar de tratar cada jornada de forma aislada. Siguiendo el proceso CRISP-DM (Wirth & Hipp, 2000), se depuró el conjunto de datos de Imran (2020), que reúne 1197 registros y 15 variables; se construyeron variables de historial por equipo; se aplicó selección de variables; y se compararon cinco familias de modelos evaluadas con una partición temporal que evita la fuga de información. La hipótesis planteaba alcanzar al menos un 80% de exactitud (accuracy). El mejor modelo, un **Random Forest**, **obtuvo un 87.0%** sobre datos no vistos, confirmando la hipótesis y superando holgadamente la línea base trivial de 73.2%.

Palabras clave: minería de datos, clasificación supervisada, ingeniería de variables temporales, productividad, industria textil, CRISP-DM, Random Forest.

1. Introducción

La industria de la confección textil (garment industry) constituye uno de los sectores manufactureros más intensivos en mano de obra del mundo. En este tipo de producción, la unidad operativa fundamental no es el trabajador individual sino el **equipo**, y el indicador que gobierna la planificación es la **productividad**: la razón entre lo efectivamente producido y lo que se esperaba producir en una jornada. A cada equipo se le asigna diariamente una productividad objetivo, y el cumplimiento o incumplimiento de esa meta determina los tiempos de entrega, los costos por horas extra y, en definitiva, la rentabilidad de la fábrica.

El problema práctico es que la productividad de un equipo es altamente variable y depende de numerosos factores: la complejidad de la prenda (reflejada en el tiempo estándar o SMV), el volumen de trabajo en proceso, las horas extra, los incentivos económicos, el número de trabajadores, los tiempos ociosos y los cambios de estilo de producción. Debido a esta variabilidad, el incumplimiento de la meta suele **constatarse recién al cerrar la jornada**, cuando ya no es posible reasignar recursos ni intervenir. La gestión, por tanto, opera de manera reactiva.

Frente a este escenario, el presente proyecto propone un enfoque **predictivo y proactivo**: anticipar, a partir de la información operativa disponible y —de manera distintiva— del **historial reciente de desempeño de cada equipo**, si éste alcanzará su meta en la jornada en curso. La pregunta de investigación que articula el trabajo es: *¿es posible predecir si un equipo cumplirá su meta hoy a partir de su comportamiento reciente y de sus variables operativas?*

El dominio y el conjunto de datos utilizados fueron introducidos originalmente por Imran et al. (2019) y posteriormente difundidos a través del repositorio de la Universidad de California en Irvine (Imran, 2020), constituyéndose en un caso de referencia para el estudio de la productividad laboral con aprendizaje automático. A diferencia de buena parte de los trabajos previos, que modelan la productividad como un valor continuo, aquí se aborda como un problema de **clasificación categórica** y se pone el acento en dos desafíos metodológicos: la **construcción de variables**

temporales por equipo y la **selección de variables de entrada**, incluyendo la decisión deliberada de prescindir del predictor más obvio para demostrar la robustez del modelo.

2. Marco conceptual

A fin de que el informe sea comprensible más allá del lenguaje técnico, se precisan los conceptos centrales que sustentan el trabajo.

2.1 Aprendizaje supervisado y clasificación

El **aprendizaje supervisado** consiste en entrenar un modelo con ejemplos previamente etiquetados, de modo que aprenda la relación entre un conjunto de variables de entrada y una variable de salida conocida. Cuando esa salida es una categoría, se habla de **clasificación**. En este estudio la salida es binaria: cumple (1) o no cumple (0) la meta de productividad.

2.2 Discretización del objetivo

La variable original de productividad real es continua (toma valores entre 0 y 1). Para convertir el problema en una clasificación, se aplica una **discretización**: se compara, en cada registro, la productividad real con la objetivo y se asigna la etiqueta correspondiente. Esta transformación convierte una tarea de regresión en una de decisión binaria, más alineada con la necesidad operativa de la fábrica.

2.3 Ingeniería de variables temporales

La **ingeniería de variables** es la creación de nuevas variables a partir de las existentes para mejorar la capacidad predictiva. En este proyecto adquiere un rol protagónico: a partir del ordenamiento cronológico de cada equipo se derivan variables de **retardo** (lag, el valor de la jornada anterior), **media móvil** (promedio de las jornadas recientes), **tendencia** (si el desempeño sube o baja) y **antigüedad desde el último cambio de estilo**. Estas variables capturan la inercia y el momento del equipo, información que se pierde si cada jornada se analiza de forma aislada.

2.4 Codificación de variables categóricas

Los algoritmos de aprendizaje requieren entradas numéricas. Las variables categóricas (día, semana, departamento y equipo) se transforman mediante **one-hot encoding**, técnica que crea una columna binaria por cada categoría, evitando imponer un orden artificial entre ellas.

2.5 Fuga de información y validación

La **fuga de información** (data leakage) ocurre cuando el modelo accede, durante el entrenamiento, a datos que no estarían disponibles en el momento real de la predicción, lo que infla artificialmente su desempeño. Se controla con dos mecanismos: calcular las variables temporales solo con información pasada y particionar los datos respetando el orden cronológico. La **validación cruzada** estima la estabilidad del modelo entrenándolo y evaluándolo en distintos subconjuntos.

2.6 Modelos de clasificación empleados

Se comparan cinco familias vistas en el ramo. El **árbol de decisión** divide recursivamente los datos mediante preguntas sobre las variables; es interpretable pero propenso al sobreajuste. El **Random Forest** combina muchos árboles entrenados sobre muestras y variables aleatorias (bagging), reduciendo la varianza. El **AdaBoost** construye árboles de forma secuencial, dando más peso a los casos mal clasificados (boosting). El **Naive Bayes gaussiano** es un clasificador probabilístico basado en el teorema de Bayes que asume independencia entre variables. Finalmente, la **máquina**

de soporte vectorial (SVM) busca el hiperplano que mejor separa las clases y, por trabajar con distancias, requiere estandarizar las variables.

2.7 Métricas de evaluación

El **accuracy** es la proporción de predicciones correctas. Ante clases desbalanceadas resulta insuficiente, por lo que se complementa con la **matriz de confusión** (que desglosa aciertos y errores por clase) y con la **precisión**, el **recall** y el **F1** por clase. La precisión responde a «de lo que predije como cumple, cuánto era correcto»; el recall, a «de los casos que realmente cumplían, cuántos detecté».

3. Problemática, objetivos e hipótesis

3.1 Planteamiento de la problemática

La detección del bajo desempeño productivo en la fábrica es actualmente **reactiva**: se confirma al finalizar la jornada, sin margen de intervención. Esto genera incumplimientos de entrega, sobrecostos por horas extra y una supervisión que distribuye su atención sin criterios anticipatorios. Se requiere, por tanto, un mecanismo que —utilizando el comportamiento reciente de cada equipo y sus condiciones operativas— permita anticipar sistemáticamente el riesgo de incumplimiento y priorizar la supervisión sobre los equipos más vulnerables.

3.2 Objetivo general

Construir y evaluar un modelo de clasificación binaria que determine si un equipo de una fábrica textil alcanzará su productividad objetivo en una jornada dada, logrando un accuracy de al menos 80%, a partir de variables operativas y del comportamiento temporal reciente del equipo.

3.3 Objetivos específicos

1. Explorar, limpiar y preparar los datos, tratando los valores nulos, corrigiendo categorías y discretizando la variable objetivo.
2. Construir las variables temporales por equipo (retardo, media móvil, tendencia y antigüedad de estilo).
3. Aplicar selección de variables de entrada, evaluando específicamente el efecto de excluir la productividad objetivo como predictor.
4. Entrenar y comparar modelos de clasificación, evaluándolos por accuracy con validación cruzada.

3.4 Hipótesis

Es posible construir un modelo de clasificación que determine con al menos un 80% de certeza (accuracy) si un equipo de la fábrica alcanzará su productividad objetivo en una jornada dada, a partir de sus variables operativas y de su comportamiento temporal reciente.

4. Metodología

El trabajo se estructuró siguiendo las fases de **CRISP-DM** (Cross-Industry Standard Process for Data Mining; Wirth & Hipp, 2000), marco que organiza un proyecto de minería de datos en comprensión del negocio, comprensión de los datos, preparación, modelado y evaluación. Toda la implementación se realizó en Python con scikit-learn (Pedregosa et al., 2011), fijando la semilla aleatoria en 42 para garantizar la reproducibilidad de los resultados.

4.1 Comprensión del negocio

Esta fase se desarrolló en la Sección 3: se definió el problema como una clasificación binaria y se estableció la meta cuantitativa de 80% de accuracy, alineada con la necesidad de la fábrica de anticipar el cumplimiento de la productividad objetivo.

4.2 Comprensión de los datos

El conjunto de datos de Imran (2020) reúne 1197 registros y 15 columnas (11 numéricas y 4 categóricas), correspondientes a un periodo de tres meses (enero a marzo de 2015). Cada registro describe el desempeño de un equipo en una jornada y un departamento. La Tabla 1 detalla las variables.

Tabla 1

Descripción de las variables del conjunto de datos.


Variable	Tipo	Descripción
date	Fecha	Fecha de la jornada
day	Categórica	Día de la semana
quarter	Categórica	Nominalmente «trimestre»; en realidad la semana del mes
department	Categórica	Departamento (sewing / finishing)
team	Categórica	Identificador del equipo (1 a 12)
targeted_productivity	Numérica	Productividad objetivo asignada (0–1)
smv	Numérica	Standard Minute Value: tiempo estándar de la tarea
wip	Numérica	Work in progress: trabajo en proceso
over_time	Numérica	Horas extra (en minutos)
incentive	Numérica	Incentivo económico
idle_time	Numérica	Tiempo ocioso
idle_men	Numérica	Trabajadores inactivos
no_of_style_change	Numérica	Número de cambios de estilo
no_of_workers	Numérica	Número de trabajadores del equipo
actual_productivity	Numérica	Productividad real (0–1); base del objetivo

Nota. Elaboración propia con base en los datos de Imran (2020).

El análisis exploratorio comenzó por la distribución de las variables clave (Figura 1). La productividad real se concentra en valores altos, con una marcada acumulación en torno al rango 0,70–0,80, lo que anticipa un predominio de jornadas que cumplen la meta. La productividad objetivo adopta un conjunto reducido de valores discretos (escalones administrativos fijados por la gerencia), y las horas extra presentan una distribución fuertemente sesgada a la derecha, con numerosos registros en cero y una cola de valores elevados.

Figura 1

Distribución de las variables clave: productividad real, productividad objetivo y horas extra.




Nota. Elaboración propia con base en los datos de Imran (2020), procesados mediante scikit-learn (Pedregosa et al., 2011).

A continuación se examinaron las relaciones lineales entre variables numéricas mediante un mapa de calor de correlaciones (Figura 2). Se detectaron **redundancias relevantes**: la correlación entre el número de trabajadores y el tiempo estándar (no_of_workers y smv) alcanza 0.91, y entre las horas extra y el número de trabajadores (over_time y no_of_workers) 0.73. Estas correlaciones altas son esperables —equipos más grandes ejecutan tareas más extensas y acumulan más horas extra— pero implican información duplicada que se tendrá en cuenta en la selección de variables. El resto de las correlaciones es de magnitud baja a moderada, lo que sugiere que ninguna variable operativa explica por sí sola la productividad.

Figura 2

Mapa de calor de correlaciones entre las variables numéricas del conjunto de datos.



Nota. Elaboración propia con base en los datos de Imran (2020), procesados mediante scikit-learn (Pedregosa et al., 2011).

4.3 Preparación de los datos

Esta fase concentró el grueso de la manipulación. En primer lugar, se trataron los **506 valores nulos de la variable wip**. El análisis reveló que estos nulos no son aleatorios: corresponden al departamento finishing, en el que —por la naturaleza del proceso— no existe trabajo en proceso. Por ello se imputaron con el valor 0, decisión semánticamente correcta que además conserva la totalidad de los registros.

En segundo lugar, se corrigió un **error tipográfico** en la variable department, donde la categoría «sweing» debía ser «sewing»; se normalizaron además los espacios y las mayúsculas. En tercer lugar, se identificó que la variable quarter, pese a su nombre, **no representa un trimestre sino la semana del mes**; se renombró a week y se extrajo su valor numérico. Por último, la variable date se convirtió a tipo fecha, requisito indispensable para el ordenamiento temporal posterior.

La **variable objetivo** se construyó comparando, en cada registro, la productividad real con la objetivo: se asignó la etiqueta «cumple» (1) cuando la real es igual o superior a la objetivo, y «no cumple» (0) en caso contrario. El balance resultante (Figura 3) es de **875 casos «cumple» (73.1%)** frente a **322 «no cumple» (26.9%)**. Este **desbalance** es metodológicamente importante: un clasificador trivial que predijera siempre «cumple» acertaría cerca del 73.1% de las veces, por lo que ése es el piso que cualquier modelo útil debe superar de forma significativa.

Figura 3

Balance de clases de la variable objetivo (cumple).



Nota. Elaboración propia con base en los datos de Imran (2020), procesados mediante scikit-learn (Pedregosa et al., 2011).

Construcción de las variables temporales por equipo (eje del proyecto). Tras ordenar los registros por equipo y fecha, se generaron cuatro variables de historial reciente: **prod_lag1**, la productividad de la jornada inmediatamente anterior del equipo; **prod_media_movil3**, la media móvil de las tres jornadas previas, que suaviza el ruido diario; **tendencia**, un indicador binario de si la productividad venía subiendo respecto del registro anterior; y **reg_desde_cambio_estilo**, el número de jornadas transcurridas desde el último cambio de estilo, que aproxima la curva de aprendizaje del equipo ante un nuevo producto. Es fundamental destacar que **todas estas variables se calcularon exclusivamente con información pasada** (mediante desplazamientos temporales), de modo que nunca incorporan el dato del día actual. Tras eliminar el primer registro de cada equipo quedaron

1185 registros válidos para el modelado.

Codificación y definición de conjuntos. Las variables categóricas (day, week, department y team) se transformaron mediante one-hot encoding. Con el propósito de poner a prueba la robustez del modelo, se definieron deliberadamente **dos conjuntos de variables**: el **Conjunto A** (34 variables), que incluye la productividad objetivo, y el **Conjunto B** (33 variables), que la excluye. La productividad objetivo es un predictor «atajo»: al estar directamente ligada a la definición de la etiqueta, podría inflar el rendimiento sin que el modelo aprenda patrones operativos reales. Comparar ambos conjuntos permite demostrar que la predicción se sostiene en información genuina.

4.4 Análisis y tratamiento de valores atípicos (outliers)

Antes del modelado se realizó un análisis de valores atípicos sobre las variables numéricas mediante el criterio del **rango intercuartílico (IQR)**, que marca como atípico todo valor situado a más de $1,5 \cdot \text{IQR}$ por debajo del primer cuartil o por encima del tercero. La Figura 4 presenta los diagramas de caja de las principales variables operativas y la Tabla 2 resume la incidencia de atípicos por variable.

Tabla 2

Incidencia de valores atípicos por variable según el criterio IQR.


Variable	Atípicos (IQR)	% del total
no_of_style_change	147	12.3%
targeted_productivity	79	6.6%
actual_productivity	54	4.5%
idle_time	18	1.5%
idle_men	18	1.5%
incentive	11	0.9%
wip	9	0.8%
over_time	1	0.1%
smv	0	0.0%
no_of_workers	0	0.0%

Nota. Elaboración propia con base en los datos de Imran (2020).

Figura 4

Diagramas de caja de las principales variables operativas para la detección de valores atípicos.

Diagramas de caja de variables operativas (detección de valores atípicos)



Nota. Elaboración propia con base en los datos de Imran (2020), procesados mediante scikit-learn (Pedregosa et al., 2011).

El análisis arrojó tres hallazgos. Primero, algunas variables presentan valores extremos aislados pero **operativamente legítimos**: wip alcanza un máximo de 23.122 unidades, over_time de 25.920 minutos e incentive de 3.600, cifras plausibles en jornadas de equipos grandes o con lotes voluminosos, y no errores de registro. Segundo, buena parte de los «atípicos» detectados por el IQR son en realidad **artefactos de variables discretas o dispersas**: no_of_style_change se marca en un 12,3% de los casos simplemente porque su valor habitual es 0 y cualquier cambio (1 o 2) queda fuera del rango; algo análogo ocurre con idle_time e idle_men, nulos salvo en incidencias puntuales. Tercero, la variable actual_productivity registra algunos valores levemente superiores a 1 (máximo 1.12), correspondientes a jornadas de sobrecumplimiento, que no constituyen un error.

En consecuencia, la estrategia adoptada fue la **conservación justificada de los valores atípicos**, sin recorte ni winsorización, por tres razones: (i) los extremos representan eventos reales del proceso productivo —precisamente los equipos excepcionales o en dificultades que interesa predecir—, de modo que eliminarlos descartaría señal valiosa; (ii) el modelo finalmente seleccionado, el Random Forest, se basa en árboles de decisión que dividen por umbrales y son **intrínsecamente robustos a los valores atípicos**, que no distorsionan sus particiones; y (iii) para la SVM, sensible a la escala, el efecto de los extremos se neutralizó con la estandarización (StandardScaler) incluida en su flujo. El único ajuste de calidad aplicado sobre los datos crudos fue la imputación de los nulos de wip descrita en la sección anterior.

4.5 Partición temporal y control de la fuga de información


Dado que el conjunto incorpora variables de historial, **una partición aleatoria habría provocado fuga de información**: registros futuros de un equipo podrían quedar en el conjunto de entrenamiento y emplearse para predecir su propio pasado. Para evitarlo, se utilizó una **partición temporal**: se entrenó con las jornadas más antiguas (anteriores al 2015-02-26, 931 registros) y se evaluó con las más recientes (254 registros). Este esquema reproduce el escenario real de uso, en el que se predice el futuro a partir del pasado, y ofrece una estimación honesta del desempeño esperado en producción.

4.6 Modelado y selección de variables

Sobre el Conjunto B se entrenaron y compararon los cinco modelos descritos en el marco conceptual: árbol de decisión, Random Forest (300 árboles), AdaBoost (200 estimadores), Naive Bayes gaussiano y SVM con kernel radial, esta última encapsulada en un flujo que estandariza previamente las variables. La estabilidad de cada modelo se verificó mediante validación cruzada estratificada de cinco pliegues sobre el conjunto de entrenamiento.

Para la **selección de variables** se empleó la importancia que el Random Forest asigna a cada predictor (Figura 5). El resultado más destacable es que la importancia se distribuye de forma relativamente equilibrada —ningún predictor domina en solitario— y que entre los más relevantes conviven variables operativas (incentive, smv, no_of_workers, over_time) con **dos de las variables temporales construidas en este trabajo**: la media móvil (prod_media_movil3) y el retardo (prod_lag1). Esto constituye evidencia directa a favor del eje del proyecto: el historial reciente del equipo aporta poder predictivo real.

Figura 5
Importancia de variables según Random Forest sobre el Conjunto B (sin productividad objetivo).



Nota. Elaboración propia con base en los datos de Imran (2020), procesados mediante scikit-learn (Pedregosa et al., 2011).

5. Resultados

La Tabla 3 y la Figura 6 sintetizan el accuracy de cada modelo sobre el conjunto de prueba temporal. El mejor desempeño correspondió al **Random Forest, con un 87.0%**, seguido por la SVM (85.0%) y AdaBoost (81.1%). Tres de los cinco modelos alcanzaron o superaron la meta del 80%, mientras que el árbol de decisión (76.0%) y el Naive Bayes (78.0%) quedaron por debajo, aunque ambos superaron la línea base trivial de 73.2%.

Tabla 3


Comparación de accuracy por modelo sobre el conjunto de prueba (Conjunto B).

Modelo	Accuracy (test)	¿Supera 80%?
Random Forest	87.0%	Sí
SVM (RBF)	85.0%	Sí
AdaBoost	81.1%	Sí
Naive Bayes (Gaussiano)	78.0%	No
Árbol de Decisión	76.0%	No

Nota. Elaboración propia con base en los datos de Imran (2020).

Figura 6

Comparación del accuracy por modelo frente a la meta del 80% (línea roja discontinua).



Nota. Elaboración propia con base en los datos de Imran (2020), procesados mediante scikit-learn (Pedregosa et al., 2011).

La Figura 6 evidencia con claridad la jerarquía entre familias de modelos: los métodos de ensemble (Random Forest y AdaBoost) y la SVM se ubican por sobre los modelos individuales más simples. La superioridad del Random Forest es consistente con la naturaleza del problema, en el que múltiples variables interactúan de manera no lineal y ningún predictor resulta dominante, condiciones en las que la combinación de muchos árboles reduce la varianza y mejora la generalización.

5.1 Análisis de las matrices de confusión


Las matrices de confusión (Figura 7) permiten ir más allá del accuracy y observar **qué tipo de error comete cada modelo**. Tomando el mejor modelo, el Random Forest, sobre los 254 casos de prueba

(186 «cumple» y 68 «no cumple») clasificó correctamente 173 de los 186 casos que sí cumplían (recall de 93.0%) y 48 de los 68 que no cumplían (recall de 70.6%). Es decir, el modelo es muy fiable detectando a los equipos que cumplirán y, aun con la dificultad propia de la clase minoritaria, identifica a cerca de siete de cada diez equipos en riesgo de no cumplir —precisamente los casos de mayor interés operativo para la supervisión.

De forma transversal, todos los modelos exhiben un patrón coherente con el desbalance: aciertan con facilidad la clase mayoritaria («cumple») y concentran sus errores en la clase minoritaria. La SVM logra el mayor recall en «cumple» pero a costa de más falsos positivos en «no cumple», mientras que el Random Forest ofrece el mejor equilibrio entre ambas clases. Esta lectura es relevante porque, en el contexto de la fábrica, no detectar a un equipo en riesgo (un falso negativo) suele ser más costoso que una falsa alarma.

Figura 7

Matrices de confusión por modelo sobre el conjunto de prueba (Conjunto B).



Nota. Elaboración propia con base en los datos de Imran (2020), procesados mediante scikit-learn (Pedregosa et al., 2011).

5.2 Efecto del predictor «atajo»

Un resultado central del estudio es la comparación entre los conjuntos de variables. Utilizando el Random Forest, el Conjunto A (que incluye la productividad objetivo) alcanzó un 85.8%, mientras que el Conjunto B (que la excluye) obtuvo un 87.0%. El hecho de que el Conjunto B no solo iguale sino que **supere** al Conjunto A demuestra de forma contundente que el modelo **no depende del predictor «atajo»**: la capacidad predictiva proviene genuinamente de las variables operativas y, sobre todo, de las variables temporales de historial. Este hallazgo valida el enfoque metodológico y refuerza la credibilidad del modelo de cara a un uso real.


5.3 Exploración complementaria: PCA y K-Means

Como análisis complementario se aplicó una reducción de dimensionalidad mediante Análisis de Componentes Principales (PCA) y un agrupamiento no supervisado con K-Means (Figura 8). Las dos

primeras componentes principales explican únicamente el 18.8% de la varianza total, porcentaje bajo que se explica por la alta dimensionalidad introducida por la codificación one-hot. En la proyección, las clases «cumple» y «no cumple» aparecen considerablemente **solapadas**, y los clústeres hallados por K-Means no reproducen la separación entre clases. Lejos de ser un resultado negativo, esto confirma que el problema **no es trivialmente separable** en el espacio de las variables, lo que justifica el recurso a modelos supervisados no lineales como el Random Forest y dimensiona el mérito del 87% de accuracy alcanzado.

Figura 8

Proyección PCA en 2D coloreada por clase real (izquierda) y por clúster de K-Means (derecha).



Nota. Elaboración propia con base en los datos de Imran (2020), procesados mediante scikit-learn (Pedregosa et al., 2011).

6. Discusión

Los resultados confirman que es posible anticipar el cumplimiento de la productividad objetivo con un nivel de exactitud que supera la meta propuesta. Más allá de la cifra, el diseño experimental fue concebido para resistir las amenazas habituales a la validez en problemas con componente temporal. La **fuga de información** se mitigó de raíz mediante variables calculadas solo con el pasado y una partición temporal estricta; el riesgo de **predictores tramposos** se neutralizó con el Conjunto B; y la **redundancia** entre variables, detectada en el análisis exploratorio, se gestionó en la etapa de selección.

Debe leerse el accuracy, no obstante, a la luz del **desbalance de clases** (73.1% de la clase mayoritaria). Por ello el análisis se complementó con las matrices de confusión y con la línea base trivial, que el mejor modelo supera en más de trece puntos porcentuales. Entre las **limitaciones** del estudio cabe señalar el tamaño moderado del conjunto (poco más de mil registros tras la preparación), la cobertura temporal de solo tres meses —que impide capturar estacionalidades anuales— y el hecho de que las variables temporales reducen ligeramente la muestra al descartar el primer registro de cada equipo.

7. Desarrollo y validación de las recomendaciones

Con el fin de validar empíricamente las líneas de mejora propuestas (Sección 9) e ilustrar las dos advertencias metodológicas sobre la medición y la validación, se desarrollaron y evaluaron las principales recomendaciones bajo un protocolo más estricto que el de la Sección 5.

Los cambios aplicados fueron: (i) **ingeniería de variables enriquecida**, añadiendo retardos y medias móviles adicionales (retardo de dos jornadas, media móvil de cinco, delta respecto a la media reciente) y el historial de incentive y over_time, pasando de 33 a 40 variables; (ii) **validación**


walk-forward (TimeSeriesSplit de cinco particiones), que entrena y evalúa avanzando en el tiempo en lugar de un único corte; (iii) **métricas robustas**, reportando —además del accuracy— el F1 y el PR-AUC de la clase «no cumple» (la minoritaria y de mayor interés operativo); y (iv) **modelos adicionales**: gradient boosting (HistGradientBoosting, XGBoost, LightGBM) y manejo del desbalance (ponderación de clases y sobremuestreo SMOTE). La Tabla 4 y la Figura 9 resumen los resultados.

Tabla 4
Comparación de modelos bajo validación walk-forward y métricas robustas.

Modelo	Accuracy	F1 «no cumple»	PR-AUC «no cumple»
RF (base, proyecto actual)	0.794	0.599	0.669
RF (features enriquecidas)	0.808	0.599	0.670
RF + balance de clases	0.796	0.521	0.676
HistGradientBoosting	0.780	0.583	0.625
XGBoost	0.782	0.586	0.612
LightGBM + balance	0.772	0.616	0.576
XGBoost + SMOTE	0.785	0.619	0.643

Nota. Elaboración propia con base en los datos de Imran (2020).

Figura 9
Comparación de modelos en las tres métricas bajo validación walk-forward; la línea roja marca la base trivial.



Nota. Elaboración propia con base en los datos de Imran (2020), procesados mediante scikit-learn (Pedregosa et al., 2011).

Se observan cuatro hallazgos. Primero, la **validación walk-forward** —más exigente que el corte único de la Sección 5— sitúa al Random Forest en torno a 0.808 de accuracy, por debajo del 87% obtenido con una sola partición; esta cifra es más realista y **confirma el riesgo de sobreajuste** de una validación menos estricta.

Segundo, la **ingeniería de variables enriquecida** fue la palanca más efectiva: el accuracy del Random Forest subió de 0.794 a 0.808 y, sobre todo, el modelo se volvió más estable entre particiones.

Tercero, los modelos de **gradient boosting no superaron al Random Forest** con este tamaño de datos (~1185 registros): XGBoost, LightGBM e HistGradientBoosting quedaron por debajo en accuracy y PR-AUC, mostrando que un método más complejo no garantiza mejores resultados.

Cuarto, el **manejo del desbalance mejora la detección de los equipos en riesgo a costa del accuracy**: XGBoost con SMOTE eleva el F1 de «no cumple» a 0.619 (frente a 0.599 del Random

Forest), pero con menor accuracy. Esto **confirma que medir solo con accuracy puede ocultar mejoras valiosas**: si el objetivo es detectar a los equipos que no cumplirán, la métrica adecuada es el F1 o el PR-AUC, no el accuracy.

En síntesis, la mejor configuración **depende del objetivo**: para calidad predictiva global y estable, el Random Forest con variables enriquecidas (0.808 de accuracy); para maximizar la detección de equipos en riesgo, XGBoost con SMOTE (F1 de 0.619) o LightGBM con balance (F1 de 0.616). Todos los modelos superan ampliamente la base trivial (PR-AUC de 0.269).

8. Conclusiones

Primero, se diseñó e implementó un flujo completo de minería de datos conforme a CRISP-DM para predecir el cumplimiento de la productividad objetivo de equipos textiles, formulado como una clasificación binaria. Segundo, la hipótesis se **confirma**: el mejor modelo (Random Forest) alcanzó un 87.0% de accuracy sobre datos no vistos, por encima de la meta del 80% y muy por sobre la línea base de 73.2%. Tercero, las variables temporales construidas en este trabajo (media móvil y retardo de la productividad) se ubicaron entre las más importantes, validando el eje conceptual del proyecto. Cuarto, la comparación de conjuntos demostró que el modelo no depende del predictor «atajo», sustentándose en información operativa y temporal genuina.

9. Trabajo futuro

Con miras a **maximizar el desempeño predictivo** del modelo, se proponen las siguientes líneas de trabajo, ordenadas por prioridad:

- 1. Redefinir la métrica de éxito.** Dado el desbalance de clases, evaluar con **F1 o AUC-PR** en lugar del accuracy, para no penalizar las mejoras en la detección de los equipos en riesgo —que son la clase minoritaria y la de mayor interés operativo.
- 2. Adoptar una validación walk-forward** (TimeSeriesSplit), entrenando y evaluando avanzando en el tiempo, de modo que las mejoras observadas sean reales y no producto del sobreajuste.
- 3. Enriquecer la ingeniería de variables temporales** con más retardos y ventanas, medias móviles de longitud variable y retardos de incentive y over_time, no solo de la productividad.
- 4. Evaluar modelos más potentes:** algoritmos de gradient boosting (XGBoost, LightGBM) y esquemas de stacking, junto con una búsqueda sistemática de hiperparámetros bajo la validación anterior.
- 5. Tratar el desbalance de clases** (sobremuestreo o ponderación) optimizando la métrica robusta seleccionada.

En todos los casos, estas mejoras deben perseguirse controlando el **riesgo de sobreajuste**, especialmente por el tamaño moderado del conjunto (~1.185 registros): conviene establecer primero una medición y una validación correctas y solo después optimizar los modelos, evitando así mejoras que resulten ilusorias sobre datos nuevos.

Referencias

- Imran, A. A. (2020). *Productivity prediction of garment employees* [Conjunto de datos]. UCI Machine Learning Repository. <https://doi.org/10.24432/C51S6D>
- Imran, A. A., Amin, M. N., Islam Rifat, M. R., & Mehreen, S. (2019). Deep neural network approach for predicting the productivity of garment employees. En *2019 6th International Conference on Control,*

Decision and Information Technologies (CoDIT) (pp. 1402–1407). IEEE.
<https://doi.org/10.1109/CoDIT.2019.8820486>

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Rahim, M. S., Imran, A. A., & Ahmed, T. (2021). Mining the productivity data of the garment industry. *International Journal of Business Intelligence and Data Mining*, 19(3), 319–342.

Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining* (pp. 29–39).